Gestion des valeurs manquantes : comparaison de méthodes d'imputation sur données financières

DAGBO Elisée & Ly Néné Gallé

Sommaire

1 Introduction **2**

2 Données **2**
2.1 Création des valeurs manquantes 2

3 Analyse descriptive de la base avec valeurs manquantes **3**
3.1 Structure des valeurs manquantes 3
3.2 Variables qualitatives 5
3.3 Variables quantitatives 6
3.4 Liens entre variables 7

4 Méthodes d'imputation **8**
4.1 Méthode A : médiane et mode par région 8
4.2 Méthode B : imputation par analyse factorielle (FAMD) 8
4.3 Méthode C : imputation multiple par équations chaînées (MICE) 9

5 Évaluation et comparaison **9**
5.1 Variables quantitatives 10
5.2 Variables qualitatives 10
5.3 Préservation de la structure des données 10

6 Conclusion **13**

7 Bibliographie **14**

1 Introduction

Dans les bases réelles, les valeurs manquantes sont fréquentes (non-réponses, erreurs de collecte). Les ignorer ou les traiter à la légère peut biaiser les statistiques et réduire la puissance des analyses.

L'objectif de ce travail est de **comparer plusieurs méthodes d'imputation** sur des données financières d'emprunteurs. Comme la base d'origine est complète, nous y avons supprimé aléatoirement des valeurs. Nous connaissons donc les vraies valeurs et pouvons **mesurer directement l'erreur commise par chaque méthode**.

Le plan est le suivant : présentation des données, analyse descriptive de la base avec valeurs manquantes, mise en œuvre de trois méthodes d'imputation, puis évaluation et comparaison à partir des vraies valeurs.

2 Données

La base (source Kaggle) contient 500 individus et 13 variables : 9 quantitatives (âge, revenu mensuel, dépenses mensuelles, épargne, montant, durée, mensualité et taux du prêt, score de crédit) et 4 qualitatives (niveau d'éducation, statut d'emploi, type de prêt, région). Elle ne contient aucune valeur manquante. Le jeu de données semble synthétique : les résultats sont à lire comme une **illustration de méthode**.

2.1 Création des valeurs manquantes

Nous avons supprimé aléatoirement 15 % des cellules de la base, en épargnant la variable `Region`, qui sert de variable de regroupement. La base obtenue est `data_na_final.csv`.

```
# Code utilisé pour générer les NA (non exécuté ici : la base obtenue est fournie)
data_na <- vraies
n_total      <- nrow(data_na) * ncol(data_na)
n_cellules   <- nrow(data_na) * ncol(data_na[, -13])
n_na         <- round(n_total * 0.15)

set.seed(123)
indices <- sample(n_cellules, n_na)

matrice_na <- as.matrix(data_na)
matrice_na[, -13][indices] <- NA
write_csv(as.data.frame(matrice_na), "data/data_na_final.csv")
```

Vérifications faites sur les fichiers fournis : les cellules non manquantes de `data_na_final.csv` sont identiques à celles de `DATA.csv` (**oui**). La proportion de valeurs manquantes est de **15 %** sur l'ensemble des colonnes et de **16.2 %** hors `Region`.

3 Analyse descriptive de la base avec valeurs manquantes

3.1 Structure des valeurs manquantes

TABLE 1 – Valeurs manquantes par variable

Variable	Nb NA	% NA
Taux_Interet_Pret_Pct	95	19
Epargne	94	18.8
Duree_Pret_Mois	87	17.4
Type_Pret	85	17
Statut_Emploi	82	16.4
Revenu_Mensuel	82	16.4
Depenses_Mensuelles	81	16.2
Mensualite_Pret	81	16.2
Montant_Pret	77	15.4
Age	74	14.8
Score_Credit	71	14.2
Niveau_Education	66	13.2
Region	0	0

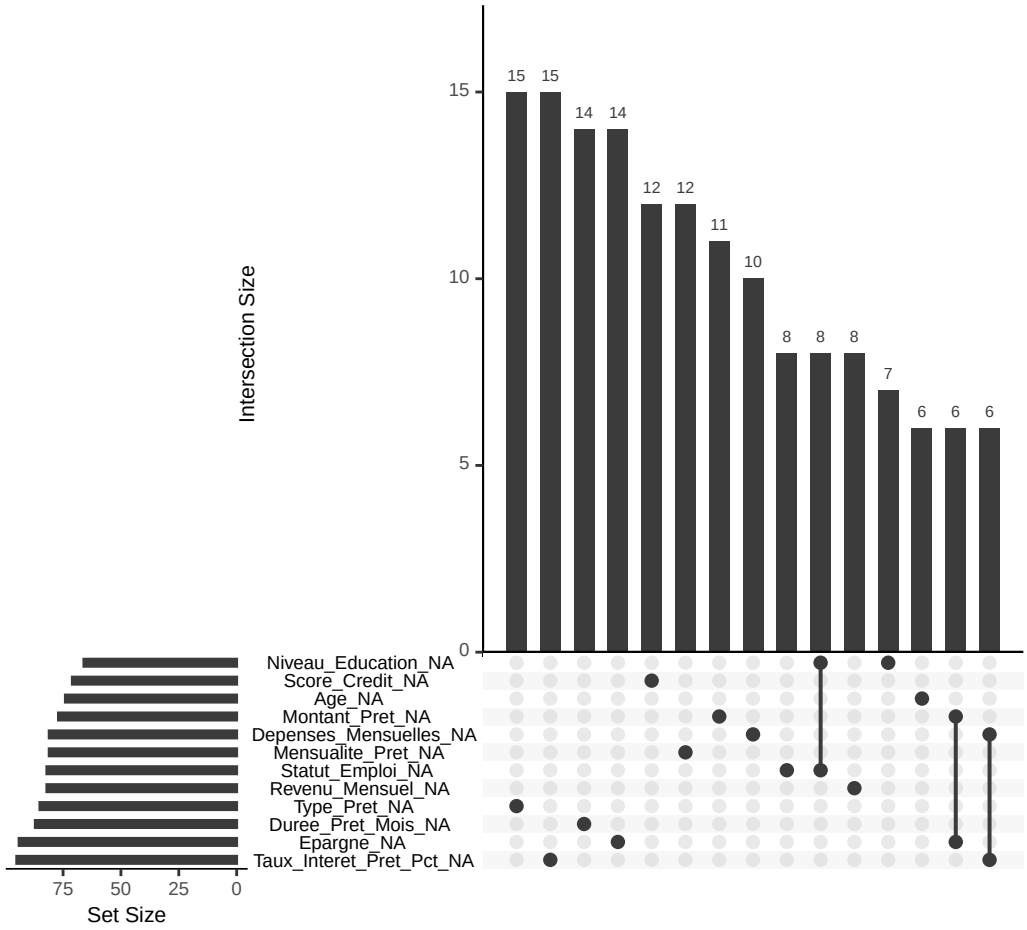
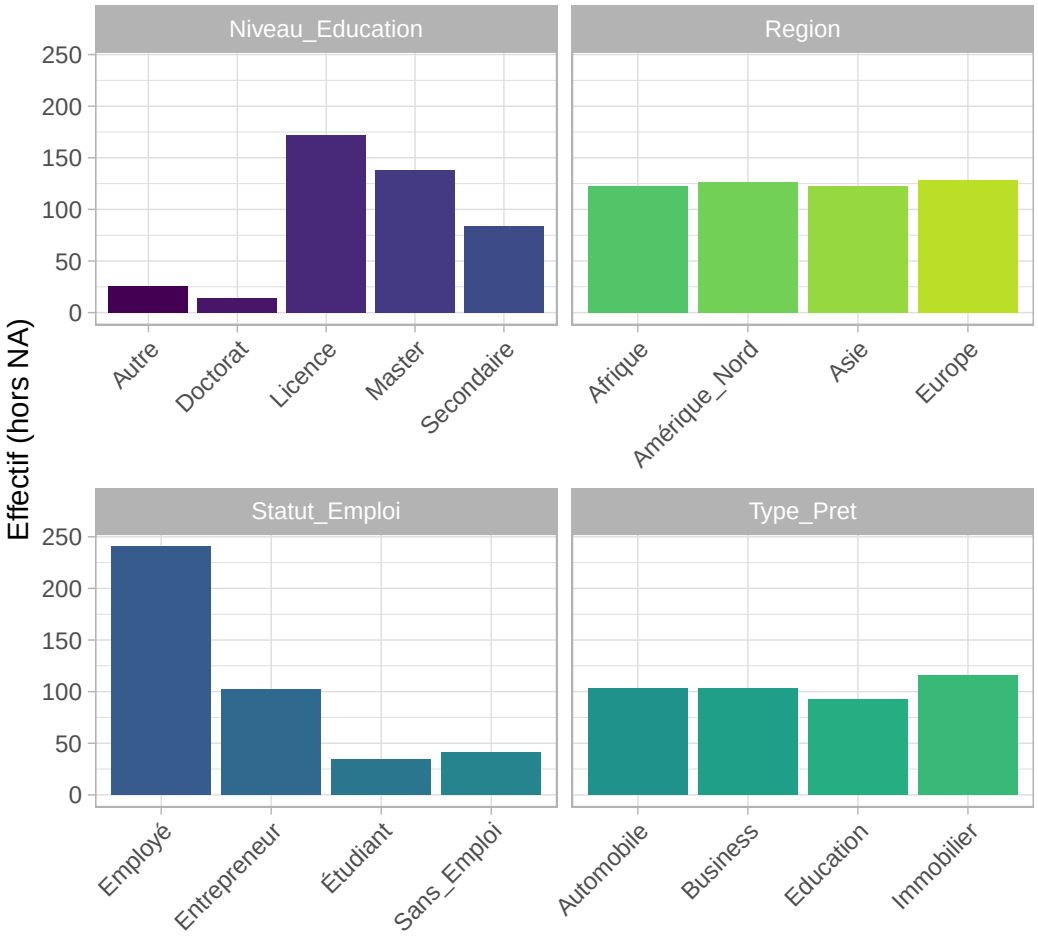


TABLE 2 – Répartition des lignes selon leur nombre de valeurs manquantes

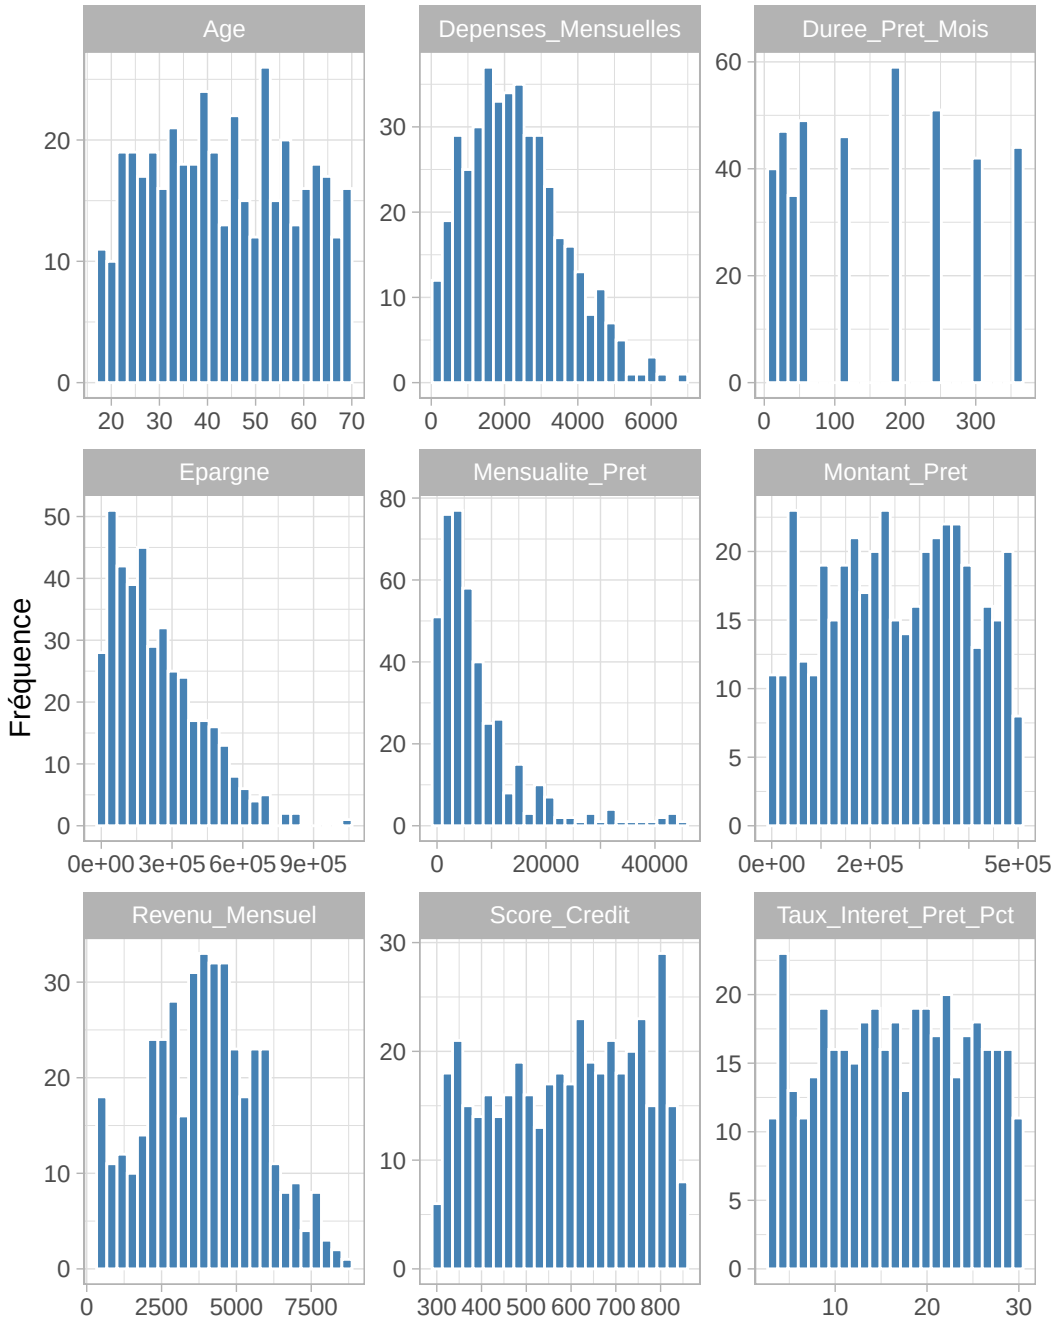
Nombre de NA par ligne	Nombre de lignes
0	67
1	132
2	138
3	110
4	33
5	15
6	5

Toutes les variables, sauf `Region`, contiennent des valeurs manquantes, souvent plusieurs par ligne. La ligne la plus touchée en compte **6** sur 13, donc aucune ligne n'est vide : toutes les observations restent exploitables pour l'imputation.

3.2 Variables qualitatives



3.3 Variables quantitatives

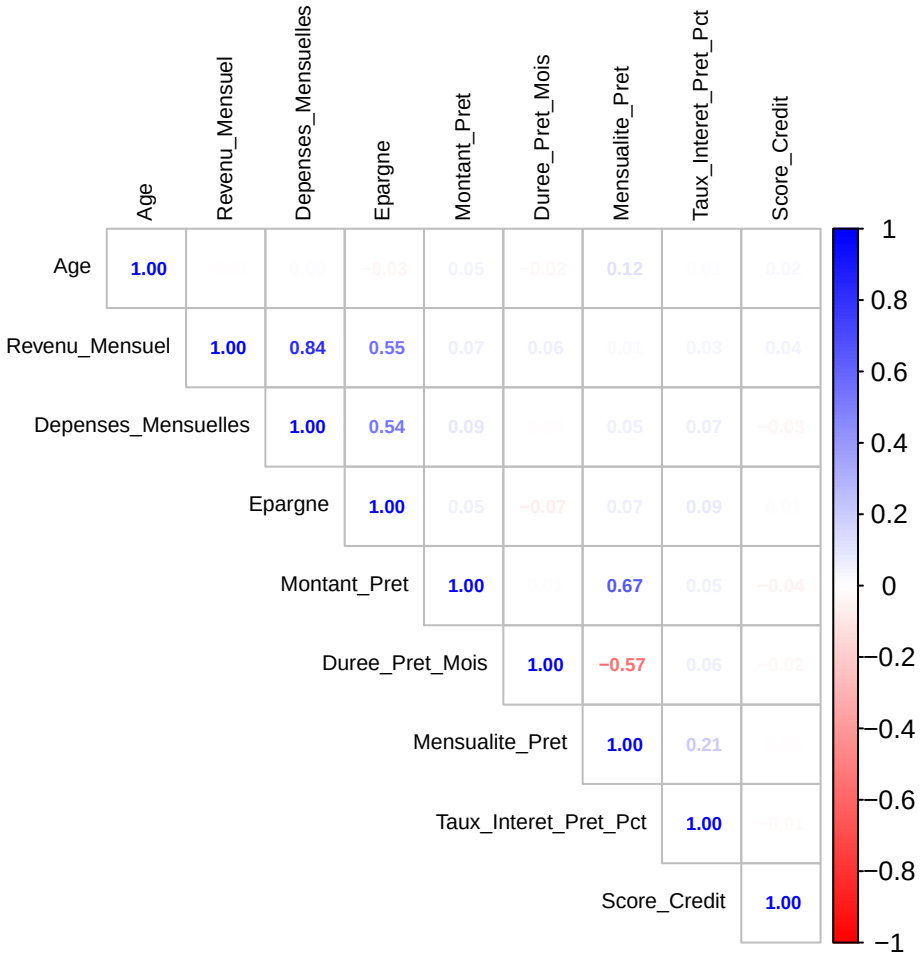


Les variables financières (épargne, mensualité, dépenses) sont asymétriques à droite, alors que l'âge, le score de crédit et le taux d'intérêt sont répartis de façon plus homogène. Ces valeurs

élevées sont **conservées** : elles sont économiquement plausibles et, surtout, supprimer des lignes avant imputation fausserait la comparaison avec les vraies valeurs.

3.4 Liens entre variables

C'est ce qui conditionne l'intérêt des méthodes « multivariées » : une variable ne peut être bien reconstituée que si elle est liée aux autres.



Les liens les plus forts sont : Depenses_Mensuelles / Revenu_Mensuel (0.84) ; Mensualite_Pret / Montant_Pret (0.67) ; Duree_Pret_Mois / Mensualite_Pret (-0.57) ; Epargne / Revenu_Mensuel (0.55) ; Depenses_Mensuelles / Epargne (0.54). À l'inverse, le score de crédit et l'âge sont pratiquement indépendants des autres variables.

Table 3 – V de Cramér entre variables qualitatives

	Niveau_Education	Statut_Emploi	Type_Pret	Region
Niveau_Education	1.00	0.10	0.07	0.08
Statut_Emploi	0.10	1.00	0.08	0.08
Type_Pret	0.07	0.08	1.00	0.14
Region	0.08	0.08	0.14	1.00

Les variables qualitatives sont peu associées entre elles : les imputer à partir des autres variables sera difficile.

4 Méthodes d'imputation

Trois méthodes, de la plus simple à la plus élaborée, sont appliquées à **toutes** les variables pour pouvoir les comparer sur le même terrain.

4.1 Méthode A : médiane et mode par région

Chaque valeur manquante est remplacée par la **médiane** de sa région (variables quantitatives) ou par le **mode** de sa région (variables qualitatives). La médiane est préférée à la moyenne car de nombreuses distributions sont asymétriques.

```
mode_stat <- function(x) {
  x <- x[!is.na(x)]
  ux <- unique(x)
  ux[which.max(tabulate(match(x, ux)))]
}

imp_A <- na_data |>
  group_by(Region) |>
  mutate(across(all_of(vars_quanti), ~ replace_na(.x, median(.x, na.rm = TRUE))),
         across(all_of(vars_quali_na), ~ replace_na(.x, mode_stat(.x)))) |>
  ungroup()
```

4.2 Méthode B : imputation par analyse factorielle (FAMD)

L'imputation par analyse factorielle des données mixtes (`missMDA::imputeFAMD`) reconstitue les valeurs manquantes à partir d'un nombre réduit d'axes (ici 3). Elle exploite les corrélations entre variables et traite à la fois les variables quantitatives et qualitatives.

```r
res_B <- imputeFAMD(as.data.frame(na_data), ncp = 3)
imp_B <- as_tibble(res_B$completeObs)[, names(na_data)]
```

4.3 Méthode C : imputation multiple par équations chaînées (MICE)

MICE construit pour chaque variable un modèle à partir des autres, de façon itérative. On génère **5 jeux imputés** ; pour la comparaison, on retient la **moyenne** des 5 imputations (variables quantitatives) ou la **modalité la plus fréquente** (variables qualitatives).

```r
imp_mice <- mice(as.data.frame(na_data), m = 5, seed = 123, printFlag = FALSE)
completes <- lapply(1:5, function(k) complete(imp_mice, k))

imp_C <- na_data
for (v in vars_quanti) {
  i <- is.na(na_data[[v]])
  imp_C[[v]][i] <- rowMeans(sapply(completes, function(d) d[[v]][i]))
}
for (v in vars_quali_na) {
  i <- which(is.na(na_data[[v]]))
  imp_C[[v]][i] <- factor(
    sapply(i, function(r) {
      tb <- table(sapply(completes, function(d) as.character(d[[v]][r])))
      names(tb)[which.max(tb)]
    }),
    levels = levels(na_data[[v]]))
}
```

Aucune valeur manquante ne subsiste dans les trois bases imputées :

```
A B C
0 0 0
```

5 Évaluation et comparaison

La comparaison se fait **uniquement sur les cellules qui étaient manquantes**, en confrontant la valeur imputée à la vraie valeur.

— **Variables quantitatives** : erreur quadratique moyenne normalisée, `NRMSE = RMSE / écart-type de la vraie variable`. Une valeur proche de 1 équivaut à imputer la moyenne ; plus elle est basse, meilleure est la méthode ; au-delà de 1, la méthode fait pire que la moyenne.
— **Variables qualitatives** : taux de bonne classification, comparé à la part de la modalité majoritaire (référence « on prédit toujours la modalité la plus fréquente »).

5.1 Variables quantitatives

TABLE 4 – NRMSE par variable et par méthode (plus bas = meilleur)

Variable	n_NA	A. Médiane / mode	B. FAMD	C. MICE
Age	74	1.03	1.01	1.03
Revenu_Mensuel	82	1.02	0.71	0.60
Depenses_Mensuelles	81	1.05	0.78	0.72
Epargne	94	1.02	0.78	0.85
Montant_Pret	77	1.00	0.96	0.88
Duree_Pret_Mois	87	1.14	1.07	1.09
Mensualite_Pret	81	1.03	0.90	0.79
Taux_Interet_Pret_Pct	95	1.08	1.10	1.19
Score_Credit	71	1.05	1.04	1.09

5.2 Variables qualitatives

TABLE 5 – Taux de bonne classification (%) ; Reference = part de la modalité majoritaire

Variable	n_NA	Reference	A. Médiane / mode	B. FAMD	C. MICE
Niveau_Education	66	38.8	33.3	31.8	22.7
Statut_Emploi	82	57.4	56.1	56.1	45.1
Type_Pret	85	26.4	25.9	27.1	22.4

5.3 Préservation de la structure des données

Une bonne imputation doit aussi conserver les **distributions** et les **liens entre variables**.

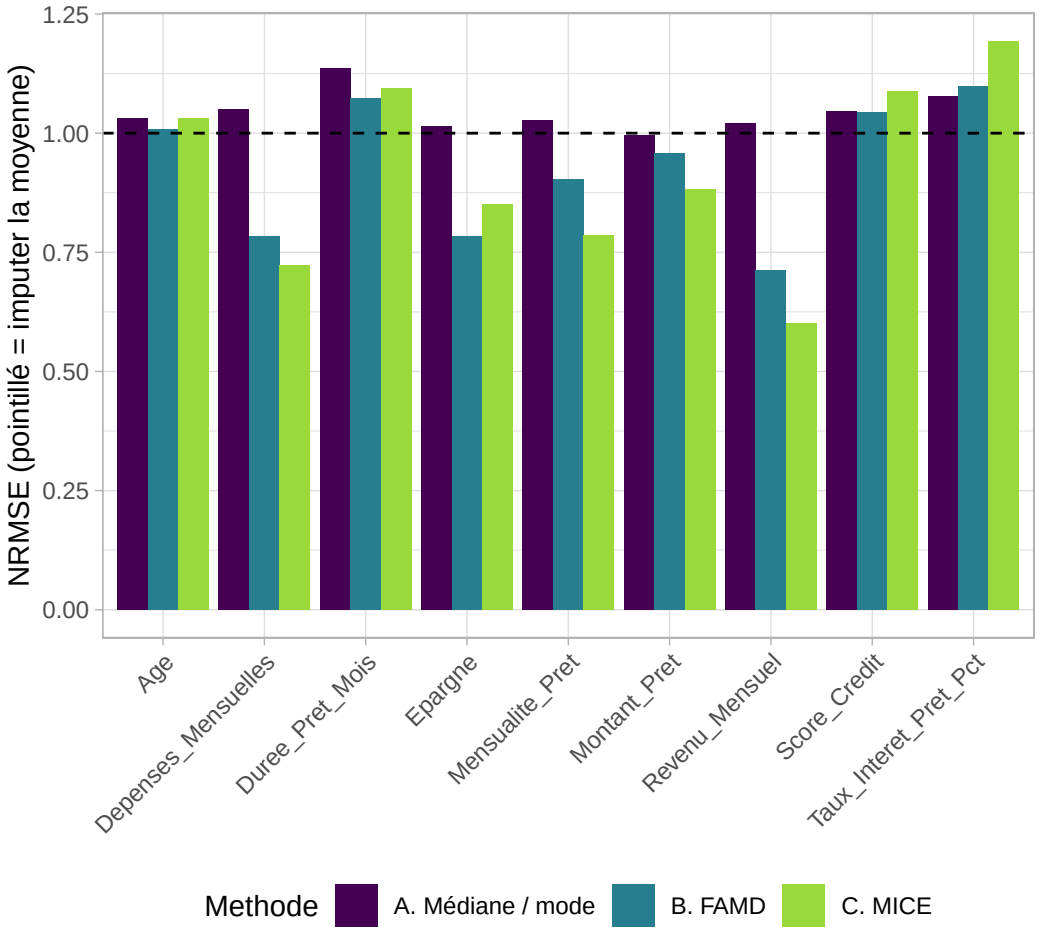

NRMSE (pointillé = imputer la moyenne)
1.25
1.00
0.75
0.50
0.25
0.00
Age
Depenses_Mensuelles
Duree_Pret_Mois
Epargne
Mensualite_Pret
Montant_Pret
Revenu_Mensuel
Score_Credit
Taux_Interet_Pret_Pct
Methode
A. Médiane / mode
B. FAMD
C. MICE

FIGURE 1

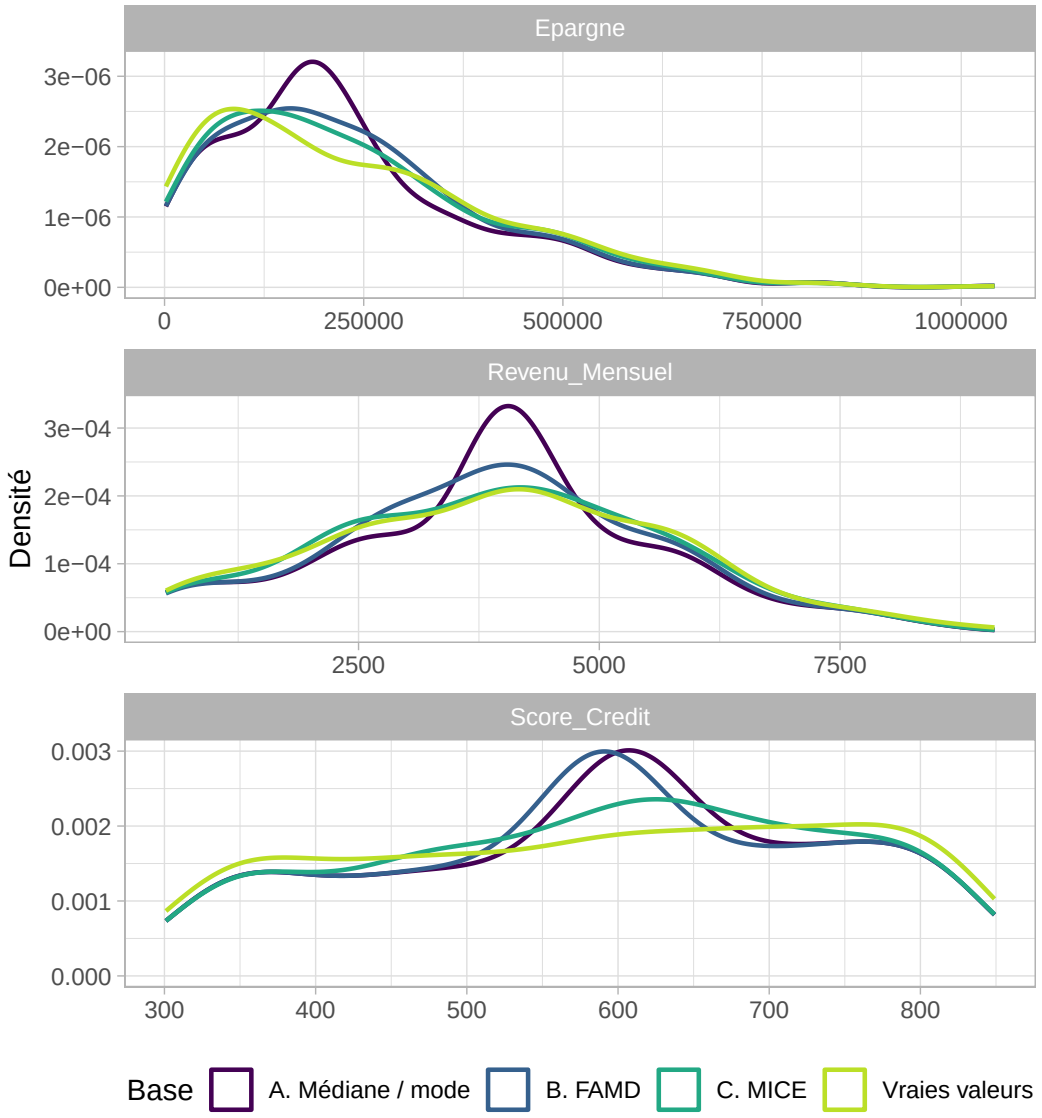


TABLE 6 – Corrélations de Spearman après imputation

Paire	Vraies valeurs	A. Médiane / mode	B. FAMD	C. MICE
Revenu_Mensuel / Depenses_Mensuelles	0.83	0.67	0.83	0.87
Revenu_Mensuel / Epargne	0.56	0.41	0.59	0.59
Montant_Pret / Mensualite_Pret	0.66	0.55	0.61	0.64

Lecture. La méthode A (médiane par région) fabrique un pic artificiel au centre de la distribution (revenu, épargne, score de crédit) et **affaiblit les corrélations** (0,83 devient 0,67 pour revenu / dépenses). La méthode B (FAMD) est la plus proche des corrélations réelles pour revenu / dépenses et revenu / épargne, tandis que MICE les conserve également bien, mais renforce légèrement la corrélation revenu / dépenses (0,87 contre 0,83). Pour le score de crédit, les trois méthodes concentrent les valeurs imputées autour du centre, ce qui déforme la distribution d'origine, plutôt plate.

6 Conclusion

Variables quantitatives. Les deux méthodes multivariées font mieux que la médiane par région : NRMSE moyen de 0.93 (FAMD) et 0.92 (MICE), contre 1.04 pour la médiane. FAMD et MICE sont pratiquement équivalentes en moyenne, et le gain est concentré sur les variables liées entre elles (revenu, dépenses, épargne, mensualité). Un NRMSE moyen proche de 1 signifie que, sur l'ensemble des variables, on ne fait guère mieux que d'imputer la moyenne.

Variables qualitatives. Le taux de bonne classification moyen est de 38.4 % (A. Médiane / mode), 38.3 % (B. FAMD), 30.1 % (C. MICE), à comparer à une référence moyenne de 40.9 % pour la modalité majoritaire. Aucune méthode ne dépasse clairement la référence : comme les variables qualitatives sont presque indépendantes des autres (V de Cramér faibles), il n'y a pas d'information à exploiter. MICE fait même moins bien que le mode, probablement parce que ses modèles s'ajustent sur du bruit.

Lecture générale. Une méthode multivariée (FAMD, MICE) n'est utile que lorsque les variables à reconstituer sont liées aux autres : c'est le cas du revenu, des dépenses, de l'épargne, du montant et de la mensualité du prêt (corrélations fortes en section 3.4), pas du score de crédit ni de l'âge. Pour ces dernières, on ne peut pas espérer mieux que la moyenne, et le choix de la méthode relève surtout de la préservation des distributions et des corrélations (section 5.3).

Limites.

- Les valeurs manquantes ont été créées **complètement au hasard** (MCAR), ce qui est le cas le plus favorable. Des NA liés à la valeur elle-même ou à d'autres variables poseraient davantage de difficultés.
- Une seule base de NA a été simulée. Répéter l'expérience avec plusieurs tirages donnerait des résultats plus robustes.
- Pour MICE, la moyenne des 5 imputations est utilisée pour comparer, ce qui est favorable à la méthode en erreur quadratique mais ne reflète pas l'incertitude liée à l'imputation.
- La mensualité du prêt est calculable exactement à partir du montant, du taux et de la durée : une imputation qui exploiterait cette formule ferait bien mieux que les méthodes génériques testées ici. Ce n'est pas étudié dans ce travail.

— Les données semblent synthétiques (par exemple, la mensualité du prêt est une fonction exacte du montant, du taux et de la durée, et dépasse le revenu mensuel pour une partie des emprunteurs) : les conclusions sont à prendre comme une illustration méthodologique.

7 Bibliographie

— van Buuren, S., & Groothuis-Oudshoorn, K. (2011). *mice : Multivariate Imputation by Chained Equations in R.* Journal of Statistical Software, 45(3).
— Josse, J., & Husson, F. (2016). *missMDA : A Package for Handling Missing Values in Multivariate Data Analysis.* Journal of Statistical Software, 70(1).
— Kaggle. Jeu de données de profils financiers d'emprunteurs (lien exact à compléter).